

Preprocessing_News

August 4, 2023

1 Pre-processing News Data

1.1 Bài toán

Dữ liệu gồm n văn bản phân vào 10 chủ đề khác nhau. Cần biểu diễn mỗi văn bản dưới dạng một vector số thể hiện cho nội dung của văn bản đó.

1.2 Sử dụng phương pháp mã hóa: TF-IDF

Cho tập gồm n văn bản: $D = \{d_1, d_2, \dots, d_n\}$. Tập từ điển tương ứng được xây dựng từ n văn bản này có độ dài là m - Xét văn bản d có $|d|$ từ và t là một từ trong d . Mã hóa tf-idf của t trong văn bản d được biểu diễn:

$$\begin{aligned} \text{tf}_{t,d} &= \frac{f_t}{|d|} \\ \text{idf}_{t,d} &= \log \frac{n}{n_t}, \quad n_t = |\{d \in D : t \in d\}| \\ \text{tf-idf}_{td} &= \text{tf}_{t,d} \times \text{idf}_{t,d} \end{aligned} \tag{1}$$

- Khi đó văn bản d được mã hóa là một vector m chiều. Các từ xuất hiện trong d sẽ được thay bằng giá trị tf-idf tương ứng. Các từ không xuất hiện trong d thì thay là 0

2 Các bước làm

2.1 Chuẩn bị các thư viện cần thiết

```
[1]: !pip install pyvi
```

```
Requirement already satisfied: pyvi in /usr/local/lib/python3.10/dist-packages (0.1.1)
```

```
Requirement already satisfied: scikit-learn in /usr/local/lib/python3.10/dist-packages (from pyvi) (1.2.2)
```

```
Requirement already satisfied: sklearn-crfsuite in /usr/local/lib/python3.10/dist-packages (from pyvi) (0.3.6)
```

```
Requirement already satisfied: numpy>=1.17.3 in /usr/local/lib/python3.10/dist-packages (from scikit-learn->pyvi) (1.22.4)
```

```
Requirement already satisfied: scipy>=1.3.2 in /usr/local/lib/python3.10/dist-packages (from scikit-learn->pyvi) (1.10.1)
```

```
Requirement already satisfied: joblib>=1.1.1 in /usr/local/lib/python3.10/dist-
```

```

packages (from scikit-learn->pyvi) (1.3.1)
Requirement already satisfied: threadpoolctl>=2.0.0 in
/usr/local/lib/python3.10/dist-packages (from scikit-learn->pyvi) (3.2.0)
Requirement already satisfied: python-crfsuite>=0.8.3 in
/usr/local/lib/python3.10/dist-packages (from sklearn-crfsuite->pyvi) (0.9.9)
Requirement already satisfied: six in /usr/local/lib/python3.10/dist-packages
(from sklearn-crfsuite->pyvi) (1.16.0)
Requirement already satisfied: tabulate in /usr/local/lib/python3.10/dist-
packages (from sklearn-crfsuite->pyvi) (0.9.0)
Requirement already satisfied: tqdm>=2.0 in /usr/local/lib/python3.10/dist-
packages (from sklearn-crfsuite->pyvi) (4.65.0)

```

```

[2]: import os
import matplotlib.pyplot as plt
import numpy as np

from sklearn.datasets import load_files
from pyvi import ViTokenizer
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.feature_extraction.text import TfidfTransformer
from sklearn.pipeline import Pipeline

%matplotlib inline

```

```

[3]: from google.colab import drive
drive.mount('/content/drive')

```

Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).

2.2 Load dữ liệu từ thư mục

Cấu trúc thư mục như sau

- data/news_vnexpress/
 - Kinh tế:
 - * bài báo 1.txt
 - * bài báo 2.txt
 - Pháp luật
 - * bài báo 3.txt
 - * bài báo 4.txt

```

[4]: #Có thể chỉnh lại đường dẫn thư mục cho phù hợp
INPUT = 'data/news_vnexpress'
os.makedirs("images",exist_ok=True) # thư mục lưu các các hình ảnh trong quá
↳ trình huấn luyện và đánh giá

```

```
[5]: # statistics
print('Các nhãn và số văn bản tương ứng trong dữ liệu')
print('-----')
n = 0
for label in os.listdir(INPUT):
    print(f'{label}: {len(os.listdir(os.path.join(INPUT, label)))}')
    n += len(os.listdir(os.path.join(INPUT, label)))

print('-----')
print(f"Tổng số văn bản: {n}")
```

Các nhãn và số văn bản tương ứng trong dữ liệu

```
-----
kinh-doanh: 262
suc-khoe: 162
the-thao: 173
phap-luat: 59
thoi-su: 59
khoa-hoc: 144
giao-duc: 105
doi-song: 120
giai-tri: 201
du-lich: 54
.ipynb_checkpoints: 0
-----
Tổng số văn bản: 1339
```

```
[6]: # load data
data_train = load_files(container_path=INPUT, encoding="utf-8")
print('mapping:')
for i in range(len(data_train.target_names)):
    print(f'{data_train.target_names[i]} - {i}')

print('-----')
print(data_train.filenamees[0:1])
# print(data_train.data[0:1])
print(data_train.target[0:1])
print(data_train.data[0:1])

print("\nTổng số văn bản: {}".format(len(data_train.filenamees)))
```

```
mapping:
.ipynb_checkpoints - 0
doi-song - 1
du-lich - 2
giai-tri - 3
giao-duc - 4
khoa-hoc - 5
```

```
kinh-doanh - 6
phap-luat - 7
suc-khoe - 8
the-thao - 9
thoi-su - 10
```

```
-----
['/content/drive/MyDrive/ML_course/Preprocessing_practice/Assignment/News_VNExpr
ess_/news_vnexpress/khoa-hoc/00133.txt']
[5]
['Mời độc giả đặt câu hỏi tại đây\n']
```

Tổng số văn bản: 1339

2.3 Chuyển dữ liệu dạng text về ma trận (n x m) bằng TF-IDF

- Bạn cần viết đoạn mã tương ứng trong cell bên dưới. Theo các bước được gợi ý

```
[ ]: # load dữ liệu các stopwords

#---> Code ở đây

# Chuyển hoá dữ liệu text về dạng vector TF
#   - loại bỏ từ dừng
#   - sinh từ điển

#---> Code ở đây

# Hàm thực hiện chuyển đổi dữ liệu text thành dữ liệu số dạng ma trận
# Input: Dữ liệu 2 chiều dạng numpy.array, mảng nhãn id dạng numpy.array

data_preprocessed = #Code ở đây

X = data_preprocessed # thuộc tính
Y = data_train.target #nhãn

print(f"\nSố lượng từ trong từ điển: {len(module_count_vector.vocabulary_)}")
print(f"Kích thước dữ liệu sau khi xử lý: {X.shape}")
print(f"Kích thước nhãn tương ứng: {Y.shape}")
```

```
[ ]: print(X[100].toarray())
      print(Y[100])
```

```
[ ]: print(X[100]) #Sau khi xử lý, dữ liệu được lưu dưới dạng ma trận thưa như sau:
```